






ANALISIS ALGORITMA KLASIFIKASI PADA DATASET DETEKSI PHISHING WEBSITE

Kelompok 8





ANGGOTA



M. Nabil Maulana (2208107010011)

Irfan Rizadi (2208107010062)

Maulana Fikri (2208107010042)

Indriani Miza Alfiyanti (2208107010026)

Raihan Firyal (2208107010084)



Dataset

Web Page Phishing Detection Dataset (Kaggle)

- 11.430 sampel data
- 89 kolom fitur
- Karakteristik: URL, hostname, struktur HTML, fitur teknis
- Tujuan: Memprediksi website phishing menggunakan 4 model klasifikasi dan membandingkan performanya



Proses Awal

Pemahaman Dataset

- Sumber: Kaggle "Web Page Phishing Detection Dataset" (2020-2024)
- Statistik deskriptif → analisis karakteristik data
- Visualisasi distribusi target → melihat keseimbangan kelas
- Korelasi antar fitur → identifikasi pola hubungan

Pra-pemrosesan Data

- Penanganan missing values → tidak ditemukan nilai kosong
- Normalisasi data → StandardScaler untuk fitur numerik
- Pembagian data → 80% training, 20% testing
- Implementasi Stratified K-Fold Cross Validation (5 fold)

Model 1: Logistic Regression

- Akurasi: Tertinggi di antara semua model
- AUC: 0.92 (terbaik)
- Log Loss: 0.3490 (terendah)
- Kelebihan: Prediksi probabilitas sangat akurat dan stabil
- Konsistensi: Performa baik untuk TP (923) dan TN (957)
- Parameter optimal: Ditemukan melalui GridSearchCV



Model 2: K-Nearest Neighbors

[KNN]

- Akurasi: Terendah di antara semua model
- AUC: 0.67
- Log Loss: 0.6513
- Kelebihan: Implementasi sederhana
- Kelemahan: False Negative tinggi (487), True Positive rendah (573)
- Kurang mampu membedakan kelas secara konsisten



Model 3: Naive Bayes

- Akurasi: Lebih baik dari KNN
- AUC: 0.87
- Log Loss: 1.0888
- Kelebihan: Baik dalam mengidentifikasi True Negative (974)
- Kelemahan: False Negative tinggi (403)
- Probabilitas kurang terkalibrasi meski AUC baik




Model 4: Decision Tree

- Akurasi: Kedua tertinggi
- AUC: 0.87
- Log Loss: 1.4227 (buruk untuk prediksi probabilitas)
- Kelebihan: Kemudahan interpretasi, keseimbangan prediksi baik
- TP (893) dan TN (951) tinggi
- Parameter optimal: Kedalaman pohon dan `min_samples_split` dioptimalkan



Perbandingan Model

Model	Akurasi	AUC	Log Loss	CV Accuracy	CV Std Dev
Logistic Regression	87.02%	0,92	0,3490	87.25%	0,0009
KNN	63.69%	0,67	0,6513	64.10%	0,0018
Naive Bayes	76.06%	0,87	1,0888	76.33%	0,0025
Decision Tree	85.32%	0,87	1,4227	85.54%	0,0014



Confusion Matrix

Model	True Negative	False Positive	False Negative	True Positive
Logistic Regression	957	148	137	923
KNN	779	326	487	573
Naive Bayes	974	131	403	657
Decision Tree	951	154	167	893

Kesimpulan

Logistic Regression adalah model terbaik secara keseluruhan:

- Akurasi tertinggi
- AUC tertinggi (0.92)
- Log Loss terendah (0.3490)
- Keseimbangan prediksi sangat baik

Decision Tree menunjukkan performa kedua terbaik dalam klasifikasi

Naïve Bayes efisien tetapi kurang akurat dalam prediksi probabilitas

K-NN performa terendah dalam mengidentifikasi kelas positif

THANK YOU

