

Logistic Regression, K-Nearest Neighbor, Naïve Bayes, Decision Tree

disusun untuk memenuhi Tugas
Machine Learning A

Oleh:

M. Nabil Maulana	(2208107010011)
Irfan Rizadi	(2208107010062)
Maulana Fikri	(2208107010042)
Indriani Miza Alfiyanti	(2208107010026)
Raihan Firyal	(2208107010084)



DEPARTEMEN INFORMATIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS SYIAH KUALA

BANDA ACEH

2025

BAB I

PENDAHULUAN

1.1 Latar Belakang

Data merupakan komponen penting dalam pengambilan keputusan di berbagai bidang, mulai dari kesehatan, lingkungan, hingga keuangan. Tantangan utama dari data yang semakin kompleks adalah bagaimana mengolahnya menjadi informasi yang bermanfaat. Machine learning, khususnya algoritma klasifikasi, menjadi solusi efektif dalam mengenali pola dari data dan memprediksi suatu kejadian berdasarkan karakteristik yang telah dipelajari sebelumnya.

Setiap algoritma klasifikasi seperti Logistic Regression, K-Nearest Neighbors (KNN), Naive Bayes, dan Decision Tree memiliki keunggulan tersendiri tergantung pada struktur dan jenis dataset. Oleh karena itu, diperlukan evaluasi menyeluruh terhadap performa masing-masing model dengan menggunakan metrik seperti akurasi, log loss, confusion matrix, dan ROC curve. Dalam penelitian ini juga dilakukan tuning hyperparameter menggunakan GridSearchCV untuk meningkatkan kinerja model. Hasil analisis kemudian divisualisasikan untuk mempermudah pemahaman dan perbandingan efektivitas antar model.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana performa model klasifikasi Logistic Regression, KNN, Naive Bayes, dan Decision Tree dalam memprediksi label pada dataset yang digunakan?
2. Algoritma mana yang memberikan akurasi dan performa terbaik berdasarkan hasil evaluasi metrik seperti akurasi, log loss, confusion matrix, dan ROC curve?
3. Bagaimana pengaruh tuning hyperparameter terhadap peningkatan kinerja dari masing-masing model?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

- Membangun dan melatih beberapa model klasifikasi seperti Logistic Regression, KNN, Naive Bayes, dan Decision Tree terhadap dataset tertentu.
- Melakukan evaluasi performa dari masing-masing model menggunakan metrik evaluasi yang relevan.
- Melakukan visualisasi terhadap hasil evaluasi untuk memudahkan analisis perbandingan antar model.
- Menentukan model klasifikasi terbaik berdasarkan hasil evaluasi dan tuning parameter.

BAB II

TINJAUAN PUSTAKA

2.1 Konsep Supervised Learning

Supervised learning adalah salah satu pendekatan dalam machine learning di mana model dilatih menggunakan data berlabel, yaitu data yang sudah memiliki input dan output yang diketahui. Tujuan dari supervised learning adalah membangun fungsi pemetaan dari input ke output, sehingga model dapat melakukan prediksi terhadap data baru yang belum pernah dilihat sebelumnya. Pendekatan ini terbagi menjadi dua jenis utama, yaitu klasifikasi (untuk prediksi kategori) dan regresi (untuk prediksi nilai kontinu). Proses pelatihan melibatkan pembelajaran dari kesalahan (error) yang dihasilkan oleh prediksi awal untuk memperbaiki model secara iteratif.

2.2 Algoritma Logistic Regression

Logistic Regression adalah algoritma klasifikasi yang digunakan untuk memprediksi probabilitas suatu kejadian dalam bentuk nilai antara 0 dan 1. Meskipun namanya mengandung "regression", algoritma ini digunakan untuk klasifikasi biner maupun multi kelas. Logistic Regression menggunakan fungsi sigmoid (logistic function) untuk memetakan nilai input ke dalam rentang probabilitas. Model ini bekerja dengan mengoptimalkan bobot parameter menggunakan teknik seperti Gradient Descent untuk meminimalkan fungsi loss, seperti log loss. Keunggulan algoritma ini terletak pada kesederhanaan, interpretabilitas, dan efisiensinya terhadap data linier.

2.3 Algoritma K-Nearest Neighbor (K-NN)

K-Nearest Neighbor (K-NN) adalah algoritma non-parametrik yang digunakan untuk klasifikasi dan regresi. Dalam klasifikasi, K-NN menentukan kelas suatu data baru berdasarkan mayoritas kelas dari k tetangga terdekat dalam ruang fitur. Kedekatan antar data diukur menggunakan metrik jarak, seperti Euclidean distance. K-NN tidak memerlukan proses pelatihan eksplisit, melainkan menyimpan seluruh data pelatihan dan melakukan prediksi berdasarkan pencarian tetangga pada saat inferensi. Kelebihannya adalah kesederhanaan dan efektivitas dalam kasus di mana hubungan antar data kompleks, namun kelemahannya terletak pada waktu komputasi yang tinggi saat prediksi dan sensitivitas terhadap skala fitur.

2.4 Algoritma Naïve Bayes

Naive Bayes adalah algoritma klasifikasi berbasis probabilistik yang menggunakan Teorema Bayes dengan asumsi kuat bahwa fitur-fitur bersifat independen satu sama lain. Meskipun asumsi ini sering tidak sepenuhnya realistis, algoritma ini menunjukkan performa yang baik dalam berbagai kasus, terutama pada dataset berukuran besar dan berdimensi tinggi. Naïve Bayes menghitung probabilitas dari setiap kelas terhadap data input dan memilih kelas dengan probabilitas tertinggi sebagai hasil prediksi. Kelebihan utama algoritma ini adalah efisiensi komputasi dan kinerja yang baik pada data dengan distribusi bersih dan jelas.

2.5 Algoritma Decision Tree

Decision Tree adalah algoritma klasifikasi yang membagi data ke dalam kelompok berdasarkan fitur-fitur yang paling informatif secara hierarkis. Model ini membentuk struktur pohon di mana setiap node internal merepresentasikan keputusan berdasarkan nilai suatu fitur, dan setiap daun (leaf) menunjukkan hasil klasifikasi. Proses pembentukan pohon melibatkan pemilihan fitur terbaik berdasarkan kriteria seperti Gini Index atau Entropy (Information Gain). Keunggulan utama dari Decision Tree adalah kemudahannya dalam interpretasi, fleksibilitas terhadap data kategorikal maupun numerik, serta kemampuannya menangani data dengan outlier atau missing values. Namun, model ini rentan terhadap overfitting jika pohon terlalu dalam.

BAB III PEMAHAMAN DATASET

3.1 Sumber Dataset

Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle, dengan judul "Web Page Phishing Detection Dataset". Dataset ini dirilis dalam rentang tahun 2020–2024 dan telah digunakan dalam berbagai penelitian untuk mengembangkan serta mengevaluasi sistem pendeteksi phishing berbasis machine learning.

Dataset ini dapat diakses melalui tautan resmi:

<https://www.kaggle.com/datasets/shashwatwork/web-page-phishing-detection-dataset/data>

Pemilihan dataset ini dilakukan karena memiliki struktur fitur yang kaya, jumlah data yang besar, dan target kelas yang jelas, sehingga sangat sesuai untuk keperluan klasifikasi menggunakan berbagai algoritma supervised learning.

3.2 Deskripsi Dataset

Dataset ini terdiri dari 11.430 data sampel dan 89 kolom, di mana setiap baris merepresentasikan satu website dengan berbagai fitur yang berkaitan dengan URL, hostname, struktur HTML, dan karakteristik teknis lainnya. Dataset ini memiliki dua jenis variabel: fitur numerik dan kategori (yang telah dikodekan secara numerik), serta satu kolom target (label).

➤ Fitur/Variabel

Beberapa fitur penting dalam dataset ini antara lain:

Fitur	Deskripsi
length_url	Panjang URL dari halaman web
nb_dots, nb_hyphens	Jumlah titik dan tanda hubung pada URL
ratio_digits_url	Rasio jumlah digit terhadap panjang URL
shortest_words_raw	Panjang kata terpendek dalam URL mentah
avg_word_path	Rata-rata panjang kata dalam path URL
safe_anchor	Persentase anchor tag yang mengarah ke domain yang aman
ratio_digits_url	Rasio karakter angka dalam URL

➤ **Target class**

Kolom target pada dataset ini adalah status, yang merepresentasikan label dari masing-masing website:

- legitimate (0): Situs web yang aman dan tidak berbahaya.
- phishing (1): Situs web yang digunakan untuk penipuan atau serangan phishing.

Kolom status ini telah diencoding ke dalam format numerik menggunakan LabelEncoder pada proses prapemrosesan, di mana 0 menunjukkan website legitimate, dan 1 menunjukkan website phishing. Nilai ini digunakan sebagai variabel target dalam pelatihan dan pengujian model klasifikasi.

3.3 Statistik Deskriptif

	length_url	length_hostname	ip	nb_dots	nb_hyphens	nb_at	nb_qm	nb_and	nb_or	nb_eq	...	empty_title
count	11430.000000	11430.000000	11430.000000	11430.000000	11430.000000	11430.000000	11430.000000	11430.000000	11430.0	11430.000000	...	11430.000000
mean	61.126684	21.090289	0.150569	2.480752	0.997550	0.022222	0.141207	0.162292	0.0	0.293176	...	0.124759
std	55.297318	10.777171	0.357644	1.369686	2.087087	0.155500	0.364456	0.821337	0.0	0.998317	...	0.330460
min	12.000000	4.000000	0.000000	1.000000	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	...	0.000000
25%	33.000000	15.000000	0.000000	2.000000	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	...	0.000000
50%	47.000000	19.000000	0.000000	2.000000	0.000000	0.000000	0.000000	0.000000	0.0	0.000000	...	0.000000
75%	71.000000	24.000000	0.000000	3.000000	1.000000	0.000000	0.000000	0.000000	0.0	0.000000	...	0.000000
max	1641.000000	214.000000	1.000000	24.000000	43.000000	4.000000	3.000000	19.000000	0.0	19.000000	...	1.000000

8 rows × 13 columns

Gambar 3.3 Statistik deskriptif fitur numerik pada dataset deteksi phishing

Statistik deskriptif digunakan untuk memperoleh gambaran umum mengenai sebaran dan karakteristik nilai dari fitur-fitur dalam dataset. Berdasarkan hasil describe(), sebagian besar fitur memiliki nilai numerik bertipe integer dan float, dengan rentang nilai yang bervariasi.

Sebagai contoh, fitur length_url memiliki rata-rata sebesar 61.13 dan maksimum 1641, yang menunjukkan bahwa terdapat URL yang sangat panjang. Fitur ip merupakan fitur biner dengan nilai antara 0 hingga 1, menunjukkan apakah URL tersebut menggunakan alamat IP atau tidak. Beberapa fitur seperti nb_dots, nb_hyphens, dan nb_at merepresentasikan jumlah simbol tertentu dalam URL, yang memiliki nilai minimum 0 dan maksimum yang cukup tinggi (misalnya nb_hyphens mencapai 43), mengindikasikan kemungkinan adanya pola tertentu pada situs phishing.

BAB IV

EKSPLORASI DAN PRA-PEMROSESAN DATA

Tahapan eksplorasi dan pra-pemrosesan data merupakan langkah awal yang penting dalam proyek machine learning. Pada tahap ini, data dianalisis untuk memahami struktur, kualitas, dan distribusi masing-masing fitur, serta dilakukan serangkaian transformasi untuk memastikan data siap digunakan dalam proses pelatihan model. Adapun proses yang dilakukan dijelaskan sebagai berikut:

4.1 Penanganan Missing Values

Langkah awal yang dilakukan adalah mengevaluasi keberadaan nilai kosong (missing values) dalam dataset. Berdasarkan hasil inspeksi, tidak ditemukan nilai kosong pada fitur-fitur yang tersedia. Oleh karena itu, proses imputasi atau penghapusan data tidak diperlukan, dan keseluruhan data dapat digunakan secara langsung dalam proses pemodelan tanpa kehilangan informasi.

4.2 Normalisasi/Standarisasi Data

Beberapa algoritma klasifikasi seperti K-Nearest Neighbor dan Logistic Regression sensitif terhadap skala data. Untuk mengatasi hal ini, dilakukan proses normalisasi menggunakan metode StandardScaler dari pustaka scikit-learn. Teknik ini mengubah distribusi nilai fitur agar memiliki rata-rata 0 dan standar deviasi 1. Proses ini memastikan bahwa setiap fitur memiliki kontribusi yang seimbang dalam perhitungan jarak atau gradien pada algoritma yang digunakan.

4.3 Analisis Korelasi

Selanjutnya dilakukan analisis korelasi antar fitur untuk memahami hubungan linear yang mungkin terjadi di antara variabel-variabel numerik. Visualisasi korelasi dilakukan menggunakan heatmap dari pustaka seaborn. Hasil visualisasi menunjukkan adanya korelasi positif dan negatif pada beberapa fitur, namun tidak ditemukan multikolinearitas ekstrem yang dapat mempengaruhi performa model secara signifikan. Informasi ini bermanfaat untuk mendukung pemilihan fitur yang relevan dan interpretasi hasil model.

4.4 Pembagian Data (Train-Test Split / Cross Validation)

Dataset dibagi menjadi dua bagian utama, yaitu data latih (training set) sebesar 80% dan data uji (testing set) sebesar 20%. Pembagian ini dilakukan secara acak dengan mempertahankan distribusi label (stratifikasi) untuk memastikan representasi yang seimbang antara kelas. Selain itu, untuk meningkatkan validitas hasil evaluasi, digunakan teknik Stratified K-Fold Cross Validation dengan jumlah lipatan (fold) sebanyak 5. Teknik ini memastikan bahwa setiap fold memiliki proporsi kelas yang sama dengan dataset awal, sehingga menghasilkan evaluasi model yang lebih konsisten dan tidak bias terhadap distribusi data.

BAB V

IMPLEMENTASI MODEL

5.1 Implementasi Logistic Regression, K-NN, Naïve Bayes, dan Decision Tree

Dalam penelitian ini, empat algoritma klasifikasi telah diimplementasikan, yaitu Logistic Regression, K-Nearest Neighbor (K-NN), Naïve Bayes, dan Decision Tree. Setiap model dikembangkan menggunakan pustaka scikit-learn (sklearn) yang umum digunakan dalam praktik machine learning di Python. Inisialisasi model dilakukan dengan parameter dasar yang disesuaikan agar proses pelatihan berjalan optimal dan reproduisibel. Penambahan parameter seperti `random_state` dan `max_iter` diterapkan untuk memastikan konsistensi hasil dan konvergensi pelatihan model, khususnya pada Logistic Regression.

1. Berikut merupakan konfigurasi awal dari masing-masing model:
2. Logistic Regression: `LogisticRegression(max_iter=1000, random_state=42)`
3. K-Nearest Neighbor: `KNeighborsClassifier()`
4. Naïve Bayes: `GaussianNB()`
5. Decision Tree: `DecisionTreeClassifier(random_state=42)`

Model-model ini kemudian digunakan dalam proses pelatihan dan evaluasi terhadap dataset yang telah melalui tahapan pra-pemrosesan, seperti normalisasi dan pembagian data latih dan uji. Seluruh proses pelatihan dilakukan dengan mempertimbangkan validasi silang (*cross-validation*) untuk meningkatkan keandalan hasil evaluasi.

5.5 Parameter dan Justifikasi Pemilihan Parameter

Untuk meningkatkan performa model dan memperoleh parameter terbaik, dilakukan proses hyperparameter tuning menggunakan teknik GridSearchCV. Pendekatan ini memungkinkan eksplorasi sistematis terhadap kombinasi parameter yang mungkin, dan memilih kombinasi yang memberikan hasil terbaik berdasarkan metrik akurasi.

Adapun rincian parameter yang dituning dan alasan pemilihannya adalah sebagai berikut:

1. Logistic Regression

Parameter `C` dieksplorasi dalam beberapa nilai (0.01, 0.1, 1, 10) untuk menentukan tingkat regularisasi terbaik. Selain itu, digunakan `solver='saga'` yang mendukung regularisasi L1, L2, dan ElasticNet. Parameter `penalty` dan `l1_ratio` digunakan untuk membandingkan efektivitas masing-masing teknik regularisasi dalam mempengaruhi akurasi model.

2. K-Nearest Neighbor (K-NN)

Algoritma K-NN dievaluasi dengan berbagai nilai `n_neighbors` (3 hingga 15) untuk mengetahui pengaruh jumlah tetangga terhadap performa klasifikasi. Selain itu, parameter `weights` diuji dalam bentuk `uniform` dan `distance` untuk melihat apakah

pemberian bobot berdasarkan jarak dapat meningkatkan akurasi. Beberapa metrik jarak seperti euclidean, manhattan, dan minkowski juga diuji dengan parameter $p = [1, 2]$.

3. Naive Bayes

Karena model Gaussian Naive Bayes hanya memiliki satu parameter utama, yaitu `var_smoothing`, maka dilakukan eksplorasi pada rentang nilai kecil ($1e-09$ hingga $1e-05$) untuk mencegah probabilitas nol dan meningkatkan kestabilan perhitungan probabilistik.

4. Decision Tree

Model Decision Tree dituning dengan variasi `max_depth` (None, 10, 20, 30) untuk mengontrol kedalaman pohon, serta `min_samples_split` untuk menentukan jumlah minimum sampel dalam pemisahan cabang. Selain itu, parameter `max_features` diuji dengan nilai 'sqrt', 'log2', dan None untuk mengetahui pengaruh jumlah fitur yang dipertimbangkan dalam setiap pemisahan.

Proses tuning dilakukan secara menyeluruh dan disesuaikan dengan karakteristik masing-masing algoritma. Hasil tuning ini memberikan kontribusi signifikan dalam menentukan performa terbaik yang dapat dicapai oleh setiap model klasifikasi yang digunakan dalam penelitian ini.


```
# Inisiasi model dengan parameter awal
models = {
    'Logistic Regression': LogisticRegression(max_iter=1000, random_state=42),
    'KNN': KNeighborsClassifier(),
    'Naive Bayes': GaussianNB(),
    'Decision Tree': DecisionTreeClassifier(random_state=42)
}

param_grids = {
    'Logistic Regression': {
        'C': [0.01, 0.1, 1, 10],
        'solver': ['saga'],
        'penalty': ['l1', 'l2', 'elasticnet'],
        'l1_ratio': [0.0, 0.5, 1.0], # untuk elasticnet
        'max_iter': [100, 200]
    },
    'KNN': {
        'n_neighbors': [3, 5, 7, 9, 11, 13, 15],
        'weights': ['uniform', 'distance'],
        'metric': ['euclidean', 'manhattan', 'minkowski'], # metrik jarak tambahan
        'p': [1, 2] # parameter p untuk Minkowski
    },
    'Naive Bayes': {
        'var_smoothing': [1e-09, 1e-08, 1e-07, 1e-06, 1e-05] # untuk GaussianNB
    },
    'Decision Tree': {
        'max_depth': [None, 10, 20, 30],
        'min_samples_split': [2, 5, 10],
        'max_features': ['sqrt', 'log2', None] # Hapus 'auto'!
    }
}
```

Gambar di atas menunjukkan proses inisialisasi model machine learning dan penentuan ruang pencarian hyperparameter yang akan digunakan dalam proses tuning. Empat algoritma yang digunakan adalah Logistic Regression, K-Nearest Neighbors (KNN), Naive Bayes, dan Decision Tree. Masing-masing model diatur dengan parameter awal tertentu dan disiapkan ruang hyperparameter yang berbeda-beda sesuai karakteristik algoritmanya. Misalnya, Logistic Regression memiliki parameter seperti C, solver, dan penalty, sedangkan KNN mengatur jumlah tetangga (n_neighbors), bobot (weights), dan metrik jarak (metric). Naive Bayes menggunakan parameter smoothing, dan Decision Tree mengatur kedalaman maksimum (max_depth), jumlah minimum sampel untuk pemisahan (min_samples_split), serta jumlah fitur maksimum (max_features). Proses ini bertujuan untuk mempersiapkan model dalam pencarian kombinasi parameter terbaik guna menghasilkan performa klasifikasi yang optimal.

Proses Pelatihan Dan Evaluasi Model Klasifikasi


Logistic Regression



	precision	recall	f1-score	support
0.0	0.87	0.87	0.87	1105
1.0	0.86	0.87	0.87	1060
accuracy			0.87	2165
macro avg	0.87	0.87	0.87	2165
weighted avg	0.87	0.87	0.87	2165

Hasil pelatihan model Logistic Regression, di mana model ini mencapai akurasi sebesar 0.8684. Parameter terbaik yang diperoleh dari proses GridSearchCV adalah C=10, l1_ratio=0.0, max_iter=200, penalty='l2', dan solver='saga'. Evaluasi performa model menunjukkan nilai precision, recall, dan f1-score yang konsisten di angka 0.87 untuk kedua kelas (0 dan 1), dengan jumlah data yang seimbang antara kelas negatif dan positif. Ini menunjukkan bahwa model memiliki kemampuan prediksi yang stabil dan andal dalam mengklasifikasikan data.

K-Nearest Neighbors



	precision	recall	f1-score	support
0.0	0.62	0.70	0.66	1105
1.0	0.64	0.54	0.58	1060
accuracy			0.62	2165
macro avg	0.63	0.62	0.62	2165
weighted avg	0.63	0.62	0.62	2165

Hasil pelatihan model K-Nearest Neighbors (KNN) dengan akurasi sebesar 0.6245. Parameter optimal yang digunakan yaitu metric='manhattan', n_neighbors=15, p=1, dan weights='distance'. Dari hasil evaluasi, precision dan recall untuk masing-masing kelas berada di kisaran 0.62 hingga 0.70, dengan f1-score 0.66 untuk kelas 0 dan 0.58 untuk kelas 1. Hal ini menunjukkan bahwa model KNN masih memiliki tantangan dalam mengenali kelas positif secara akurat, meskipun performanya cukup baik dalam mengenali kelas negatif.

Naive Bayes

```
Training Naive Bayes...
Training Models: 75% | ██████████ | 3/4 [08:57<02:14, 134.84s/it]Naive Bayes - Best parameters: {'var_smoothing': 1e-05}
Naive Bayes - Accuracy: 0.7533
```

	precision	recall	f1-score	support
0.0	0.71	0.88	0.78	1105
1.0	0.83	0.62	0.71	1060
accuracy			0.75	2165
macro avg	0.77	0.75	0.75	2165
weighted avg	0.77	0.75	0.75	2165

Model Naive Bayes yang dilatih menunjukkan akurasi sebesar 75,33% dengan parameter terbaik `var_smoothing` sebesar `1e-05`. Kinerja model ini cenderung tidak seimbang antara dua kelas. Untuk kelas 0, recall sangat tinggi (0,88) namun precision lebih rendah (0,71), sedangkan untuk kelas 1, precision tinggi (0,83) namun recall rendah (0,62). Hal ini menunjukkan bahwa model lebih sering mengenali kelas 0 dengan benar, tetapi cenderung melewatkan banyak data yang seharusnya diklasifikasikan sebagai kelas 1. F1-score untuk kedua kelas masing-masing adalah 0,78 dan 0,71, sedangkan nilai rata-rata makro dan rata-rata berbobot untuk precision, recall, dan f1-score semuanya berada di angka 0,75 hingga 0,77.

Decision Tree

```
Training Decision Tree...
Training Models: 100% | ██████████ | 4/4 [09:07<00:00, 136.93s/it]Decision Tree - Best parameters: {'max_depth': 10, 'max_features': None, 'min_samples_split': 5}
Decision Tree - Accuracy: 0.8517
```

	precision	recall	f1-score	support
0.0	0.85	0.86	0.86	1105
1.0	0.85	0.84	0.85	1060
accuracy			0.85	2165
macro avg	0.85	0.85	0.85	2165
weighted avg	0.85	0.85	0.85	2165

Model Decision Tree yang telah dilatih menunjukkan performa yang cukup baik dengan akurasi sebesar 85,17%. Model ini menggunakan parameter terbaik hasil tuning, yaitu kedalaman maksimum (`max_depth`) 10, semua fitur digunakan (`max_features`: None), dan minimal lima sampel untuk pemisahan node (`min_samples_split`: 5). Hasil evaluasi menunjukkan bahwa precision, recall, dan f1-score untuk kedua kelas (0 dan 1) berada di kisaran 0,84 hingga 0,86, menandakan keseimbangan performa model dalam mengklasifikasikan kedua kelas tersebut. Rata-rata makro dan rata-rata berbobot untuk semua metrik juga konsisten di angka 0,85, menunjukkan bahwa model tidak bias terhadap salah satu kelas.

Secara keseluruhan, Logistic Regression adalah model terbaik dalam kasus ini, karena memberikan performa yang paling seimbang, akurasi tertinggi, dan stabil dalam mendeteksi kedua kelas. Decision Tree bisa menjadi opsi kedua, sementara Naive Bayes dan KNN kurang direkomendasikan untuk digunakan tanpa perbaikan lebih lanjut pada data atau parameter.

BAB VI

EVALUASI MODEL

Setelah proses pelatihan model selesai dilakukan, tahap selanjutnya adalah mengevaluasi performa dari masing-masing model klasifikasi. Evaluasi dilakukan menggunakan berbagai metrik yang umum digunakan dalam tugas klasifikasi, seperti confusion matrix, akurasi, presisi, recall, dan F1-score. Selain itu, dilakukan pula analisis perbandingan antar model berdasarkan kinerja keseluruhan, serta evaluasi terhadap fungsi loss pada model tertentu.

6.1 Confusion Matrix

Confusion matrix merupakan matriks yang digunakan untuk menggambarkan kinerja algoritma klasifikasi dengan membandingkan hasil prediksi model terhadap label sebenarnya. Dalam penelitian ini, confusion matrix digunakan untuk masing-masing model, yaitu Logistic Regression, K-Nearest Neighbor, Naïve Bayes, dan Decision Tree. Matriks ini memberikan informasi mengenai jumlah True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN), yang kemudian menjadi dasar perhitungan metrik evaluasi lainnya. Visualisasi matriks dilakukan dalam bentuk heatmap untuk mempermudah interpretasi dan analisis kesalahan model.

6.2 Akurasi, Presisi, Recall, F1-score

Berbagai metrik evaluasi digunakan untuk menilai performa model secara lebih menyeluruh, yaitu:

1. Akurasi: Mengukur proporsi prediksi yang benar dibandingkan dengan total data.
2. Presisi: Mengukur sejauh mana prediksi positif yang dilakukan model benar adanya.
3. Recall (Sensitivity): Menunjukkan kemampuan model dalam mendeteksi data positif dengan benar.
4. F1-Score: Merupakan harmonisasi antara presisi dan recall, yang sangat berguna ketika data tidak seimbang.

Metrik-metrik tersebut dihitung untuk masing-masing model dan dibandingkan satu sama lain untuk mendapatkan gambaran yang komprehensif mengenai performa klasifikasi.


6.3 Perbandingan Kinerja Antar Algoritma

Hasil evaluasi menunjukkan adanya variasi performa di antara keempat model klasifikasi. Secara umum, model Decision Tree dan Logistic Regression menunjukkan kinerja yang paling stabil dengan nilai akurasi dan F1-score yang tinggi. Model K-Nearest Neighbor juga menunjukkan hasil yang baik, terutama ketika jumlah tetangga (k) diatur secara optimal. Sementara itu, Naïve Bayes memiliki keunggulan dari sisi kecepatan dan efisiensi, namun performanya sedikit lebih rendah dibandingkan model lainnya.

Perbandingan ini memberikan wawasan bahwa pemilihan model terbaik tidak hanya ditentukan oleh akurasi, tetapi juga oleh konteks penggunaan, kompleksitas model, dan waktu komputasi yang dibutuhkan.


6.4 Loss Function

Pada model Logistic Regression, evaluasi tambahan dilakukan menggunakan fungsi loss, yaitu log loss (logaritmic loss). Log loss mengukur seberapa jauh prediksi probabilistik model dari label sebenarnya. Nilai log loss yang lebih kecil menunjukkan bahwa model menghasilkan prediksi yang lebih dekat dengan nilai sebenarnya. Evaluasi log loss menjadi penting dalam konteks klasifikasi probabilistik karena memberikan informasi lebih rinci dibandingkan sekadar akurasi.



Model	True Negative (TN)	False Positive (FP)	False Negative (FN)	True Positive (TP)
Logistic Regression	957	148	137	923
K-Nearest Neighbor	779	326	487	573
Naïve Bayes	974	131	403	657
Decision Tree	951	154	167	893

Dari tabel yang diberikan, dapat dilihat bahwa Logistic Regression memiliki jumlah True Negative (TN) tertinggi dan False Positive (FP) terendah, yang menunjukkan kinerjanya yang cukup baik dalam memprediksi kelas negatif. Meskipun memiliki False Negative (FN) yang cukup tinggi dibandingkan model lainnya, True Positive (TP)-nya masih cukup tinggi, menunjukkan bahwa model ini dapat mengenali banyak kasus positif. K-Nearest Neighbor (KNN) memiliki keseimbangan yang lebih buruk antara False Positive dan False Negative, dengan TP yang relatif rendah dan FP yang tinggi, yang mengindikasikan bahwa model ini lebih sering salah dalam mengklasifikasikan kelas positif. Naïve Bayes memiliki performa yang baik dalam hal True Negative, tetapi mengalami peningkatan False Negative yang cukup signifikan, sehingga tidak sebaik Logistic Regression dalam mengidentifikasi kelas positif. Decision Tree menunjukkan keseimbangan yang cukup baik dengan True Positive dan True Negative yang tinggi, meskipun masih ada cukup banyak False Positive. Secara keseluruhan, Logistic Regression tampak sebagai model yang lebih stabil dalam memprediksi kelas positif dan negatif dibandingkan dengan model lainnya.



Model	AUC (Area Under Curve)	Log Loss	Interpretasi Singkat
Logistic Regression	0.92	0.3490	Performa terbaik, prediksi probabilistik sangat baik dan stabil.
K-Nearest Neighbor	0.67	0.6513	Performa rendah, kurang mampu membedakan kelas secara konsisten.
Naïve Bayes	0.87	1.0888	AUC baik, namun probabilitas kurang akurat (log loss tinggi).

Decision Tree	0.87	1.4227	Akurasi klasifikasi baik, tetapi probabilitas tidak terkalibrasi dengan baik.
---------------	------	--------	---

Dari tabel ini, dapat disimpulkan bahwa Logistic Regression memiliki performa terbaik dengan AUC 0.92 dan log loss terendah (0.3490), menunjukkan bahwa model ini dapat memprediksi probabilitas dengan sangat baik dan stabil. K-Nearest Neighbor memiliki AUC yang rendah (0.67) dan log loss tinggi (0.6513), yang menandakan bahwa model ini tidak cukup efektif dalam membedakan antara kelas positif dan negatif secara konsisten. Naïve Bayes menunjukkan AUC yang baik (0.87), tetapi dengan log loss yang cukup tinggi (1.0888), yang mengindikasikan bahwa meskipun model ini memiliki kemampuan klasifikasi yang cukup, probabilitas yang diprediksi tidak cukup akurat. Decision Tree juga memiliki AUC 0.87, namun log loss yang lebih tinggi (1.4227), yang mengindikasikan bahwa meskipun model ini memiliki akurasi yang baik dalam klasifikasi, probabilitas yang diprediksi kurang terkalibrasi dengan baik.

BAB VII

ANALISIS DAN VISUALISASI HASIL


Tahapan ini berfokus pada interpretasi hasil evaluasi model secara visual dan numerik, serta pemilihan model klasifikasi terbaik berdasarkan metrik kinerja yang telah dihitung. Beberapa visualisasi seperti ROC Curve, Confusion Matrix, Learning Curve, serta grafik perbandingan akurasi dan log loss digunakan untuk memperdalam analisis efektivitas prediksi masing-masing model.

7.1 Grafik Fit Model

Evaluasi performa awal dilakukan melalui kurva Receiver Operating Characteristic (ROC) yang menggambarkan hubungan antara True Positive Rate dan False Positive Rate. Selain itu, nilai AUC (Area Under the Curve) digunakan sebagai indikator seberapa baik model mampu membedakan antara dua kelas.

Visualisasi lain berupa Learning Curve juga digunakan untuk melihat kestabilan performa model terhadap variasi ukuran data latih. Hasilnya menunjukkan bahwa:



1. Logistic Regression menunjukkan kinerja terbaik dan stabil meskipun ukuran data bertambah.
2. Decision Tree menunjukkan peningkatan yang baik, namun cenderung stagnan setelah titik tertentu.
3. Naïve Bayes dan K-NN menunjukkan keterbatasan dalam peningkatan performa seiring bertambahnya data latih.



7.2 Interpretasi Hasil Model

Selain menggunakan confusion matrix, interpretasi performa model juga dilakukan melalui visualisasi diagram batang (bar chart) untuk membandingkan akurasi dan log loss dari keempat model klasifikasi. Gambar perbandingan akurasi menunjukkan bahwa Logistic Regression memiliki tingkat akurasi tertinggi, disusul oleh Decision Tree, kemudian Naïve Bayes, dan terakhir K-Nearest Neighbor (KNN). Hal ini menegaskan bahwa Logistic Regression tidak hanya unggul dalam hal probabilistik, tetapi juga dalam klasifikasi aktual.

Selanjutnya, visualisasi perbandingan log loss memperlihatkan perbedaan yang lebih mencolok antar model. Logistic Regression kembali menunjukkan performa terbaik dengan log loss terendah (~ 0.35), yang menandakan bahwa prediksi probabilitasnya sangat mendekati nilai sebenarnya. KNN berada di posisi kedua dengan log loss sekitar 0.65, sedangkan Naïve Bayes memiliki nilai log loss yang lebih tinggi (~ 1.09), meskipun akurasinya cukup baik. Model dengan log loss tertinggi adalah Decision Tree (~ 1.42), yang menunjukkan bahwa model ini cenderung tidak memberikan estimasi probabilitas yang stabil atau akurat, walaupun akurasinya tinggi.



Visualisasi ini memberikan gambaran yang jelas bahwa akurasi tinggi belum tentu diiringi dengan kualitas prediksi probabilitas yang baik, sehingga log loss menjadi metrik penting dalam mengevaluasi model klasifikasi secara lebih menyeluruh.

7.3 Model Terbaik dan Alasannya

Berdasarkan hasil evaluasi secara menyeluruh terhadap keempat model klasifikasi—meliputi akurasi, confusion matrix, ROC-AUC, log loss, learning curve, serta visualisasi perbandingan performa dapat disimpulkan bahwa Logistic Regression merupakan model terbaik dalam penelitian ini.

Beberapa alasan utama yang mendasari pemilihan ini adalah sebagai berikut:

1. Akurasi Tertinggi

Logistic Regression mencapai akurasi klasifikasi tertinggi dibanding model lainnya. Hal ini menunjukkan bahwa model ini mampu mengklasifikasikan data secara tepat dengan tingkat kesalahan yang rendah.

2. Nilai AUC Paling Tinggi (0.92)

Logistic Regression memiliki Area Under Curve (AUC) tertinggi pada ROC Curve, yang menandakan kemampuannya dalam membedakan kelas positif dan negatif secara konsisten.

3. Log Loss Terendah (~0.35)

Dengan nilai log loss yang paling rendah, model ini memberikan prediksi probabilitas yang paling akurat dan terkalibrasi dengan baik dibandingkan model lain seperti Decision Tree atau Naïve Bayes.

4. Stabilitas pada Learning Curve

Berdasarkan grafik learning curve, performa Logistic Regression meningkat secara konsisten seiring bertambahnya data latih dan menunjukkan kestabilan yang tinggi. Ini menandakan bahwa model tidak overfitting dan memiliki generalisasi yang baik.

5. Distribusi Prediksi yang Seimbang

Berdasarkan confusion matrix, Logistic Regression menunjukkan keseimbangan yang sangat baik antara True Positive dan True Negative, serta menghasilkan False Positive dan False Negative yang rendah.

6. Interpretabilitas dan Efisiensi

Logistic Regression dikenal sebagai model yang mudah diinterpretasikan secara matematis dan statistik, serta efisien dalam hal waktu pelatihan dan prediksi, menjadikannya sangat cocok untuk implementasi di dunia nyata.

Dengan mempertimbangkan berbagai metrik evaluasi dan visualisasi hasil, dapat disimpulkan bahwa Logistic Regression memberikan kombinasi terbaik antara akurasi, probabilitas yang

terkalibrasi, dan stabilitas model. Oleh karena itu, model ini direkomendasikan sebagai model utama dalam klasifikasi dataset yang digunakan dalam penelitian ini.

BAB VIII

KESIMPULAN

Penelitian ini telah mengevaluasi dan membandingkan empat algoritma klasifikasi, yaitu Logistic Regression, K-Nearest Neighbors (K-NN), Naive Bayes, dan Decision Tree, dalam memprediksi label pada suatu dataset. Seluruh model dikembangkan menggunakan pustaka scikit-learn dan dituning menggunakan GridSearchCV untuk memperoleh performa terbaik. Evaluasi dilakukan berdasarkan metrik akurasi, precision, recall, f1-score, serta ditunjang oleh visualisasi hasil klasifikasi.

Dari hasil implementasi, Logistic Regression menunjukkan performa terbaik secara keseluruhan dengan akurasi sebesar 86,84% dan nilai precision, recall, serta f1-score yang seimbang untuk kedua kelas. Hal ini menunjukkan bahwa model ini sangat stabil dan efektif dalam klasifikasi, khususnya pada data yang cenderung linier. Decision Tree menyusul di posisi kedua dengan akurasi 85,17%, serta performa yang merata antar kelas. Kelebihan model ini terletak pada kemampuannya menangani data kompleks dan interpretasi yang mudah, walaupun rentan terhadap overfitting tanpa pengaturan kedalaman pohon yang tepat.

Sementara itu, Naive Bayes mencatat akurasi 75,33%, dan walaupun cepat dan efisien, model ini menunjukkan ketidakseimbangan dalam mengenali dua kelas, terutama kurang akurat dalam mendeteksi kelas positif. Hal ini disebabkan oleh asumsi independensi antar fitur yang tidak selalu sesuai dengan kenyataan pada data. Adapun K-Nearest Neighbors menunjukkan performa paling rendah dengan akurasi 62,45%, disebabkan oleh sensitivitas terhadap parameter jumlah tetangga dan metrik jarak yang digunakan. Model ini juga mengalami kesulitan dalam mengenali pola secara konsisten, khususnya pada kelas minoritas.

Secara keseluruhan, keempat model memiliki kekuatan dan kelemahan masing-masing. Logistic Regression direkomendasikan sebagai pilihan utama untuk data dengan hubungan linier, sedangkan Decision Tree cocok untuk data kompleks yang membutuhkan interpretasi. Naive Bayes dapat digunakan untuk data besar dengan asumsi sederhana, dan K-NN hanya disarankan jika data telah diproses dan disesuaikan secara optimal. Tuning hyperparameter terbukti berperan penting dalam meningkatkan kinerja model secara signifikan, menegaskan pentingnya proses eksplorasi parameter dalam praktik machine learning.